


UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN



Licenciatura en Actuaría

Análisis Técnico

Asignatura: Estadística 3

Profesor: Luis Alfredo Gómez Ramírez

Grupo: 2602

Integrantes del equipo:

- Betanzos Frías Kevin
- Meléndez Chavero María Valeria
- Romero de la Torre Kenia Michelle

Índice

1. Ingesta y Disponibilidad de los Datos	2
1.1. Archivos alojados en GitHub	2
1.2. Archivos alojados en Google Drive	3
1.2.1. NOTA	3
2. Contextualización del Negocio y Objetivos Estratégicos	4
3. Definición Formal de las Variables de Estudio	5
3.1. Variable Dependiente (Y)	5
3.2. Variables Independientes Continuas (X_1, X_2, X_3)	5
3.3. Variable Categórica de Control	6
4. Fase 1: Análisis Descriptivo y Distribución Empírica	6
4.1. Implementación Computacional y Estadística Descriptiva	6
4.2. Interpretación Analítica y Relevancia de Negocio	8
4.3. Distribución Empírica	8
4.3.1. Consideración sobre la variable X_1 (Energy)	9
4.3.2. Análisis de Y : Popularidad del Artista (<code>artist_hotttnesss</code>)	9
4.3.3. Análisis de X_2 : Bailabilidad (<code>danceability</code>)	10
4.3.4. Análisis de X_3 : Acusticidad (<code>acousticness</code>)	11
4.3.5. Comparativa de Popularidad (Y) por Géneros	11
4.4. Hipótesis de Negocio de la Fase 1	12
5. Fase 2: Pruebas Estadísticas y Remuestreo	14
5.1. Prueba de Cuantiles y Bondad de Ajuste	14
5.1.1. Prueba de Hipótesis para el Umbral de Cuantiles	14
5.1.2. Prueba de Bondad de Ajuste Global	15
5.2. Comparación Poblacional (Prueba de Wilcoxon)	16
5.3. Pruebas de Independencia para Vectores Aleatorios	16
5.4. Hipótesis de Negocio de la Fase 2	17
6. Fase 3: Regresión No Paramétrica	18
6.1. Implementación del Estimador de Nadaraya-Watson	18
6.2. Visualización de los Ajustes	19
6.3. Evaluación del Ajuste: Error Cuadrático Medio	23
6.4. Hipótesis de Negocio de la Fase 3	23
7. Fase 4: Conclusiones y Próximos Pasos	25
7.1. Conclusiones Generales	25
7.2. Recomendaciones de Negocio	26
7.3. Próximos Pasos	27

1. Ingesta y Disponibilidad de los Datos

Como parte fundamental de las mejores prácticas en el desarrollo de proyectos analíticos y garantizando la reproducibilidad metodológica del código, el equipo de trabajo estructuró una arquitectura híbrida de almacenamiento en la nube para la base de datos del sello discográfico. Esto permite que el entorno de ejecución (cuaderno de Python) pueda compilarse eficientemente desde cualquier dispositivo con acceso a internet, optimizando el uso de memoria local.

Debido a que los datos provienen de un ecosistema digital masivo de la industria musical, el volumen físico de los registros varía de forma considerable entre tablas. Por ello, la ingesta se segmentó estratégicamente en dos repositorios virtuales de acuerdo con las capacidades físicas y restricciones de almacenamiento de las plataformas utilizadas:

1.1. Archivos alojados en GitHub

Los catálogos relacionales, tablas de características vectoriales y archivos complementarios de menor peso fueron cargados en un repositorio público de GitHub. A través de la extracción de sus enlaces crudos (*raw URLs*), la librería **pandas** realiza la lectura directa vía protocolo HTTP mediante el método `read_csv()`. Los conjuntos de datos descentralizados mediante esta plataforma son:

- `audio_features.csv`: Matriz de características acústicas extraídas del audio (X_2, X_3).
- `artist_location.csv`: Datos de geolocalización espacial de los artistas.
- `artist_tags.csv`: Etiquetas reguladas de indexación musical.
- `artist_terms.csv`: Términos frecuentes recopilados en blogs musicales.
- `song_genres.csv`: Identificador y asignación del género principal (*main_genre*).
- `song_lyrics.csv`: Frecuencia de términos lingüísticos en las letras de las canciones.

El bloque de código implementado para automatizar la lectura remota desde este repositorio sigue la estructura algorítmica ilustrada a continuación:

```
# Ejemplo de carga de datos desde GitHub
```

```
url_features = "https://raw.githubusercontent.com/.../audio_features.csv"
audio_features = pd.read_csv(url_features)
```

1.2. Archivos alojados en Google Drive

Las tablas medulares y más densas del negocio superaron los límites de almacenamiento individual permitidos por la plataforma GitHub para archivos estándar (restricción perimetral de tamaño). Específicamente, las bases `summary.csv` (que concentra todo el histórico general de las canciones e incluye la popularidad del artista Y) y `song_play_count.csv` (una matriz transaccional masiva que registra cada reproducción individual efectuada por los usuarios) debieron ser migradas a un entorno de almacenamiento en la nube de mayor capacidad.

Para solucionar esta limitación física sin romper el esquema de portabilidad multi-dispositivo, los dos archivos se consolidaron dentro de una carpeta compartida en Google Drive denominada **“Datos”**. Para acceder a ellos directamente desde el entorno virtual de Google Colab, se programó la conexión y el montaje dinámico de la unidad mediante la paquetería nativa `google.colab`:

```
# Montaje de la unidad de Google Drive
from google.colab import drive
drive.mount('/content/drive')

# Ingesta de las tablas de alta densidad (excedentes de GitHub)
ruta_summary = "/content/drive/MyDrive/Datos/summary.csv"
summary = pd.read_csv(ruta_summary)

ruta_play_count = "/content/drive/MyDrive/Datos/song_play_count.csv"
song_play_count = pd.read_csv(ruta_play_count)
```

1.2.1. NOTA

La carpeta **“Datos”** debe estar en la cuenta desde donde se abre Colab en **“Mi unidad”** con acceso directo

Esta arquitectura de despliegue garantiza que la extracción de las variables independientes de estudio (X_1, X_2, X_3), la variable dependiente de popularidad (Y) y la variable categórica estructural se ejecute de manera íntegra y transparente, sentando una infraestructura de datos sólida para las fases avanzadas de distribución empírica, remuestreo *Bootstrap* y regresión no paramétrica.

2. Contextualización del Negocio y Objetivos Estratégicos

En el ecosistema altamente dinámico e hipercompetitivo de la industria discográfica contemporánea, el éxito comercial de los lanzamientos musicales ha dejado de responder únicamente a dinámicas intangibles o azarosas. Bajo este contexto, el equipo se posiciona operativamente como el cuerpo de analistas cuantitativos corporativos del sello discográfico. La misión central consiste en descubrir rigurosamente si las características sónicas intrínsecas de las canciones poseen una relación directa y estadísticamente significativa con la métrica de éxito comercial de sus creadores: la popularidad estimada del artista.

El modelado predictivo tradicional usualmente descansa sobre supuestos rígidos de distribuciones teóricas paramétricas (como la distribución Normal o Exponencial). Sin embargo, estas asunciones teóricas tienden a fallar de forma crítica ante variables del mercado musical que exhiben asimetrías severas, comportamientos multimodales o densidades altamente concentradas en ciertos segmentos de consumo masivo. Por ello, este estudio se fundamenta estrictamente en las herramientas de la **inferencia estadística no paramétrica**. Al ser metodologías libres de supuestos distributivos (*distribution-free*), nos permiten estudiar la distribución empírica real de los datos sin sesgar las conclusiones por una mala especificación del modelo.

La resolución analítica de esta problemática dotará a la alta gerencia y a las direcciones de finanzas de directrices operativas sólidas y basadas en datos para fundamentar decisiones estratégicas sobre qué tipo de producción musical financiar. De este modo, se busca optimizar de forma eficiente la exposición comercial de los talentos en las plataformas de *streaming* y maximizar el retorno de inversión (ROI) corporativo, mitigando los riesgos inherentes al desarrollo de capital artístico en el mercado.

3. Definición Formal de las Variables de Estudio

Para estandarizar el análisis empírico, asegurar la comparabilidad de las pruebas estadísticas y dar sustento al posterior ajuste de regresión no paramétrica por Kernel, el equipo aisló y estructuró rigurosamente cinco variables clave extraídas de las bases de datos relacionales.

A continuación, se delimita formalmente la naturaleza analítica y conceptual de cada variable del estudio:

3.1. Variable Dependiente (Y)

- **Popularidad del Artista (Y):** Operacionalizada a través de la variable continua `artist_hotness`, la cual se encuentra alojada en la tabla relacional `summary`. Esta métrica representa un estimador normalizado del nivel de atracción, exposición comercial y éxito contemporáneo del talento dentro de la industria musical. Al actuar como nuestra variable de respuesta, el objetivo es modelar sus cambios condicionados a las características sonoras.

3.2. Variables Independientes Continuas (X_1, X_2, X_3)

- **Intensidad Acústica (X_1):** Representada por la variable continua `energy`, alojada estructuralmente en la tabla `summary`. Cuantifica la percepción perceptual de la intensidad, el dinamismo y la actividad de la pista de audio. Los valores cercanos a la unidad denotan composiciones altamente activas, ruidosas y veloces, mientras que valores bajos tipifican obras pausadas o minimalistas.
- **Nivel de Bailabilidad (X_2):** Operacionalizada mediante la variable continua `danceability`, indexada en la tabla `audio_features`. Describe formalmente qué tan adecuada resulta una pista para el baile social. Su cálculo algorítmico pondera elementos acústicos estructurales como la regularidad del *tempo*, la estabilidad del ritmo y la fuerza de los impactos del compás.
- **Coefficiente de Acusticidad (X_3):** Representada por la variable continua `acousticness`, localizada en la tabla `audio_features`. Mide el nivel acústico y determina analíticamente la probabilidad de que una canción haya sido creada mediante instrumentación puramente orgánica o clásica, en contraposición al empleo de sintetizadores, cajas de

ritmo o procesos netamente electrónicos. Está acotada estrictamente en el intervalo $[0,0,1,0]$.

3.3. Variable Categórica de Control

- **Género Musical Predominante (*main_genre*):** Variable cualitativa categórica alojada dentro del catálogo de la tabla `song_genres`. Funciona como un factor de estratificación y segmentación de mercado. Permitirá evaluar si la popularidad esperada está dominada sistemáticamente por ciertos estilos musicales, o si las características de sonido son transversales al éxito comercial.

Para propósitos de referencia analítica y legibilidad del reporte, la taxonomía y arquitectura de origen de las variables de estudio se sintetizan formalmente en la Tabla 1.

Cuadro 1: Taxonomía Formal y Matriz de Variables del Modelo

Identificador	Nombre en Base de Datos	Naturaleza	Tabla de Origen
Variable Y	<code>artist_hotness</code>	Continua / Dependiente	<code>summary</code>
Variable X_1	<code>energy</code>	Continua / Independiente	<code>summary</code>
Variable X_2	<code>danceability</code>	Continua / Independiente	<code>audio_features</code>
Variable X_3	<code>acousticness</code>	Continua / Independiente	<code>audio_features</code>
Factor de Control	<code>main_genre</code>	Categórica / Cualitativa	<code>song_genres</code>

4. Fase 1: Análisis Descriptivo y Distribución Empírica

4.1. Implementación Computacional y Estadística Descriptiva

Para la caracterización inicial, se emplearon funciones desarrolladas bajo programación algorítmica nativa en `Python`, garantizando la reproducibilidad y el control sobre la estimación de los momentos muestrales y cuantiles. La varianza muestral se estimó aplicando la corrección de Bessel $(n-1)$ para obtener un estimador insesgado de la dispersión poblacional:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Los resultados numéricos obtenidos mediante el procesamiento computacional de las bases de datos se sintetizan en la Tabla 2.

Cuadro 2: Estadística Descriptiva y Cuantiles Empíricos de las Variables

Variable	Momentos y Extremos				Cuantiles de Probabilidad (p)				
	Mín.	Máx.	Media	Desv. Est.	0.01	0.25	0.50	0.75	0.99
Y (artist_hotness)	0.0000	1.0825	0.4158	0.1104	0.0000	0.3643	0.4094	0.4690	0.7247
X_1 (energy)	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
X_2 (danceability)	0.0000	1.0000	0.4360	0.3840	0.0000	0.0568	0.3284	0.8633	1.0000
X_3 (acousticness)	0.0000	1.0000	0.3199	0.3613	0.0000	0.0114	0.1211	0.6528	0.9977

Adicionalmente, se realizó el conteo de frecuencias de la variable categórica `main_genre` mediante estructuras de datos tipo *hash-map* (diccionarios), cuya distribución se detalla en la Tabla 3.

Cuadro 3: Distribución de Frecuencias: Género Musical

Género	Frecuencia
Rock	3413
Electronic	998
Pop	596
Jazz	566
Metal	449
RnB	444
Rap	431
Country	365
Reggae	323
Blues	263
Folk	202
Punk	127
Latin	120
World	70
New Age	49

4.2. Interpretación Analítica y Relevancia de Negocio

- **Dinámica de la Popularidad (Y):** La distribución de `artist_hotness` presenta una media de 0,4158 y una mediana muy cercana (0,4094), lo que indica una simetría relativa en el cuerpo central de la distribución. No obstante, el valor máximo de 1,0825 frente al cuantil 99 (0,7247) evidencia una cola pesada a la derecha, confirmando que, aunque la popularidad está distribuida de forma más uniforme en el segmento medio, existe una élite de artistas que se despega drásticamente de la norma.
- **Inconsistencia en la Variable X_1 (energy):** Un hallazgo crítico derivado del análisis descriptivo es que la variable `energy` presenta una constante de valor 0,0. Estadísticamente, esto sugiere un problema de calidad de datos (ausencia de variabilidad o error en el proceso de ingesta de *features*), lo cual invalida cualquier inferencia sobre la intensidad como predictor de popularidad.
- **Polarización Acústica y Segmentación de Mercado (X_2, X_3):** Tanto la *danceability* como la *acousticness* exhiben varianzas elevadas (0,3840 y 0,3613). La distribución de `acousticness`, con una mediana de 0,1211 y un cuantil 75 de 0,6528, es indicativa de una **bimodalidad marcada**: el sello discográfico maneja un catálogo bifurcado entre producciones sintéticas masivas y piezas orgánicas, lo que requiere estrategias de posicionamiento distintas.
- **Dominio Estructural (Géneros):** La alta frecuencia del *Rock* (3,413) sobre otros géneros, como el *Pop* (596), dictamina que el activo principal de la disquera radica en el clúster de Rock. Cualquier modelo de regresión deberá ser ajustado considerando esta jerarquía, dado que el volumen de datos en Rock otorga mayor significancia estadística a las conclusiones extraídas para dicho género.

4.3. Distribución Empírica

En esta sección, se analiza la distribución de las variables continuas (Y, X_2, X_3) sin asumir modelos paramétricos. Para ello, se estima la Función de Distribución Empírica (FDE), definida para una muestra $\{x_1, \dots, x_n\}$ como:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x)$$

Para evaluar la incertidumbre de este estimador, se construyeron bandas de confianza simultáneas basadas en la desigualdad de Dvoretzky-Kiefer-Wolfowitz (DKW) al 95% de confianza ($\alpha = 0,05$), definidas por el intervalo $[F_n(x) - \epsilon, F_n(x) + \epsilon]$, donde el margen de error ϵ se calcula como $\epsilon = \sqrt{\frac{\ln(2/\alpha)}{2n}}$.

4.3.1. Consideración sobre la variable X_1 (Energy)

Tras el análisis exploratorio, se determinó que la variable **energy** presenta una varianza de 0 (todos sus valores son 0.0). Debido a esta degeneración, el cálculo de una curva de densidad y de una FDE carece de variabilidad estocástica, por lo cual se excluye de este análisis gráfico.

4.3.2. Análisis de Y : Popularidad del Artista (artist_hotttnesss)

Para visualizar la distribución, empleamos el siguiente código algorítmico:

```
# Histograma y curva de densidad
summary["artist_hotttnesss"].hist(bins=30, density=True)
summary["artist_hotttnesss"].plot(kind="density")
```




Figura 1: Histograma y densidad de popularidad del artista

Interpretación: La distribución presenta una fuerte concentración de la masa de probabilidad en torno al intervalo $[0,35, 0,55]$, con una curtosis elevada (comportamiento leptocúrtico) y una cola derecha extendida que alcanza valores superiores a 1,0. Esta forma es característica de distribuciones de popularidad en industrias creativas donde el éxito se concentra en una minoría de actores. La FDE (Figura 2) con sus bandas DKW al 95% nos permite afirmar que el 75% de la masa de datos se concentra en valores de popularidad menores a 0.46, validando que el éxito comercial es un fenómeno altamente concentrado.




Figura 2: FDE y bandas DKW al 95% para artist_hottnesss

4.3.3. Análisis de X_2 : Bailabilidad (danceability)




Figura 3: Histograma de danceability




Figura 4: FDE y bandas DKW de danceability

Interpretación: La danceability muestra una variabilidad significativa ($\sigma = 0,3840$). Su FDE presenta una pendiente variable, lo que indica que no hay una concentración única; los valores se distribuyen de manera que cubren casi todo el espectro $[0, 1]$, reflejando que el sello produce música con diversos perfiles rítmicos.

4.3.4. Análisis de X_3 : Acusticidad (acousticness)




Figura 5: Histograma de acousticness




Figura 6: FDE y bandas DKW de acousticness

Interpretación: La acusticidad presenta una distribución bimodal. La FDE crece lentamente al inicio y al final, con un salto pronunciado en los valores medios, lo que confirma que el catálogo se divide principalmente entre pistas con elementos electrónicos predominantes y pistas acústicas puras.

4.3.5. Comparativa de Popularidad (Y) por Géneros

Se filtraron los tres géneros con mayor frecuencia (Rock, Electronic, Pop) para comparar sus funciones de distribución empírica.




Figura 7: Comparativa de FDE de Y por género

Análisis Estadístico: Al observar las tres curvas en un mismo plano, se distingue una dominancia estocástica. El género *Pop* muestra una FDE desplazada hacia la derecha en comparación con el *Rock* y *Electronic*, sugiriendo que, para niveles de popularidad altos ($Y > 0,6$), el género Pop mantiene una mayor probabilidad acumulada. Esto implica que la disquera tiene mayores probabilidades de éxito masivo en lanzamientos Pop, a pesar de que el Rock posea una frecuencia absoluta mayor en el catálogo.

4.4. Hipótesis de Negocio de la Fase 1

Con base en la evidencia empírica derivada del análisis descriptivo y de las distribuciones estimadas, se presentan las conclusiones técnicas enfocadas en la toma de decisiones estratégicas para el sello discográfico:

- **Monopolio de atención en la industria (Y):** La distribución de la popularidad (`artist_hottnesss`) revela un mercado altamente concentrado. La existencia de un valor máximo de 1,0825 frente a una mediana de 0,4094 y un cuantil 99 de 0,7247 confirma la ausencia de equidad en la distribución del éxito comercial. Desde una perspectiva actuarial, la industria opera bajo un modelo de Efecto Superstar o monopolio

de atención, donde una pequeña minoría de talentos acapara la mayor parte de la popularidad. La disquera no debe buscar una estrategia de “éxito promedio”, ya que este no garantiza la rentabilidad; la estrategia debe enfocarse en identificar y financiar proyectos con potencial de convertirse en *outliers* estadísticos dentro de la cola derecha de la distribución.

- **Ausencia de estándar sónico y segmentación (X_1, X_2, X_3):** El análisis de dispersión y las formas de las densidades empíricas descartan la existencia de un estándar sónico único.
 - La variable **energy** (X_1), al presentar una varianza nula, se identifica como una variable degenerada en esta base de datos, lo que sugiere una falla en la ingesta o procesamiento de la información. No debe ser utilizada como variable predictiva en ninguna estrategia de inversión.
 - Las variables **danceability** y **acousticness** presentan alta varianza y comportamientos multimodales. Esto es una señal clara para la gerencia de que **no existe un producto musical universal**. La industria está fragmentada en nichos: una estrategia de producción que funcione para el segmento “electrónico/sintético” (acusticidad baja) fallará para el segmento “orgánico” (acusticidad alta). El sello debe especializar sus líneas de producción por perfiles sonoros en lugar de estandarizarlas.
- **Dominancia de género vs. popularidad esperada:** Al contrastar las FDEs de los tres géneros dominantes (*Rock*, *Electronic*, *Pop*), observamos que, si bien el *Rock* tiene la mayor frecuencia absoluta (3,413 registros), la FDE del género *Pop* muestra un comportamiento estocástico diferente en los rangos superiores de popularidad. Las curvas presentan intersecciones, lo que implica que el género *por sí solo* no garantiza un mayor nivel de éxito absoluto; existen artistas de alto rendimiento en todos los géneros. No obstante, la estructura de la FDE favorece ligeramente al *Pop* para alcanzar niveles de popularidad extrema, lo que sugiere que el *Pop* es un vehículo de penetración de mercado más eficiente para lanzamientos que buscan exposición masiva.
- **Certidumbre estadística y riesgo financiero:** La amplitud de las bandas DKW al 95 % es sumamente estrecha debido al gran tamaño de muestra (n). Esto dota a la disquera de un nivel de certidumbre estadística muy alto respecto al comportamiento poblacional de las variables analizadas. El margen de error (ϵ) es lo suficientemente pequeño como para que las conclusiones sobre los patrones de popularidad no sean producto del azar muestral. Por lo tanto, la gerencia puede basar sus decisiones financieras

en estos modelos con un alto grado de confianza estadística, reconociendo que el mayor riesgo de la inversión no proviene de la incertidumbre en la estimación del modelo, sino de la propia variabilidad intrínseca del mercado musical (la alta dispersión de las variables acústicas).

5. Fase 2: Pruebas Estadísticas y Remuestreo

En esta fase se formalizan las hipótesis de negocio a través de la inferencia estadística no paramétrica. Siguiendo rigurosamente las restricciones metodológicas impuestas, el cálculo de los p -valores y las regiones de rechazo se obtuvo mediante algoritmos de remuestreo *Bootstrap*, evitando el uso de aproximaciones teóricas clásicas o tablas de valores críticos asintóticos que asuman normalidad.

5.1. Prueba de Cuantiles y Bondad de Ajuste

5.1.1. Prueba de Hipótesis para el Umbral de Cuantiles

Con la finalidad de evaluar de forma no paramétrica la estructura posicional de la popularidad del artista (Y), se estableció como umbral crítico de rentabilidad el valor del cuantil 75 % poblacional, fijando la hipótesis sobre $m_0 = 0,4690246250966762$.

Justificación estadística: Al desconocer la distribución subyacente de Y , se recurrió a la prueba de signos para cuantiles. Esta es una prueba exacta y libre de distribución (*distribution-free*) que modela el conteo de observaciones por encima del umbral como una variable aleatoria con distribución Binomial (construida a partir de ensayos independientes de Bernoulli). Dado el gran tamaño de la muestra, el algoritmo utiliza la aproximación asintótica Normal de esta distribución Binomial para calcular el estadístico Z . Esto permite contrastar si la proporción observada es consistente con el cuantil teórico esperado, sin requerir supuestos previos de simetría o normalidad paramétrica en los datos originales. sin requerir supuestos de simetría o normalidad.

Tras la exclusión de empates exactos, el algoritmo contabilizó un total de 4,998 registros estrictamente mayores que m_0 y 14,999 registros menores que dicho umbral. Al someter estos

conteos a la prueba no paramétrica estandarizada, se obtuvo un estadístico de prueba:

$$Z_{\text{calc}} = -70,7230536144112$$

Dado que $|Z_{\text{calc}}| > 1,96$, se concluye el **rechazo categórico de la hipótesis nula** (H_0). Esto demuestra matemáticamente que la proporción observada en la muestra difiere de manera estadísticamente significativa del cuantil propuesto bajo independencia estocástica.

5.1.2. Prueba de Bondad de Ajuste Global

Para corroborar si la variable dependiente de popularidad se adecua a una distribución paramétrica de referencia (condición que inhabilitaría el esquema no paramétrico), se programaron desde cero tres estadísticos clásicos de bondad de ajuste basados en la distancia uniforme y cuadrática, estimando sus p -valores mediante réplicas *Bootstrap*:

Justificación estadística: La estadística de Kolmogorov-Smirnov evalúa la divergencia máxima absoluta, pero pierde poder en las colas. Por ende, se implementaron Cramér-von Mises (que integra la desviación global) y Anderson-Darling (que pondera fuertemente las colas de la distribución). Dado que los parámetros de la distribución teórica son estimados desde la misma muestra, los valores críticos tabulados clásicos pierden validez, haciendo mandatorio el uso de remuestreo *Bootstrap* paramétrico para obtener p -valores insesgados.

- **Kolmogorov-Smirnov (KS):** Registró un valor observado de 0,10090906209211081.
- **Anderson-Darling (AD):** Registró un valor observado de 403,56980922596995, con un p -valor de *Bootstrap* de 0,0000.
- **Cramér-von Mises (CvM):** Registró un valor observado de 60,187621269522786, con un p -valor de *Bootstrap* de 0,0000.

El hecho de obtener p -valores de 0,0000 en todas las pruebas cuadráticas confirma el rechazo absoluto de las hipótesis paramétricas clásicas, justificando de manera irrefutable la necesidad de aplicar modelado no paramétrico en las siguientes fases.

5.2. Comparación Poblacional (Prueba de Wilcoxon)

Con el objetivo de determinar si el factor categórico de género musical altera de forma sistemática la localización de la popularidad, se ejecutó una prueba de suma de rangos de Wilcoxon (Mann-Whitney U) para comparar las distribuciones de éxito entre clústers principales.

Justificación estadística: A diferencia de la prueba t de Student de dos muestras, que asume normalidad e igualdad de varianzas, la prueba de Wilcoxon evalúa dominancia estocástica basándose en el ordenamiento (rangos) de las observaciones combinadas. Es invariante ante transformaciones monótonas y altamente robusta ante la presencia de valores atípicos extremos observados en la cola de popularidad.

El algoritmo arrojó un estadístico de suma de rangos observado de $U = 1,051,214,5$. Al estandarizar la variable, se obtuvo un estadístico:

$$Z_{\text{Wilcoxon}} = 8,245008339818213$$

asociado a un p -valor de *Bootstrap* igual a 0,0000.

Dada la magnitud del estadístico Z ($p < 0,05$), **se rechaza contundentemente la hipótesis nula de homogeneidad distributiva**. Se concluye que existen diferencias posicionales estadísticamente significativas entre las poblaciones; el género ejerce un efecto de desplazamiento estocástico real sobre la popularidad esperada.

5.3. Pruebas de Independencia para Vectores Aleatorios

Para evaluar la existencia de dependencias entre la popularidad (Y) y sus características de sonido continuas (X_1, X_2, X_3), se programó el coeficiente de correlación de rangos de Spearman (ρ_S).

Justificación estadística: El coeficiente de correlación de Pearson asume relaciones estrictamente lineales, lo cual es restrictivo en modelado musical. Spearman, al basarse en los rangos de la distribución empírica, permite detectar asociaciones monótonas no lineales. La validación de significancia (cálculo del p -valor) se realizó vía remuestreo *Bootstrap* simulando bajo la hipótesis nula de independencia estocástica, destruyendo las ligaduras vectoriales originales para crear la distribución del estadístico de prueba.

1. **Popularidad (Y) vs. Intensidad (X_1):** Coeficiente $\rho_S = 0,5000055529523889$ con un p -valor *Bootstrap* de 1,0000. Este resultado es una consecuencia directa de la degeneración de X_1 : al ser una variable constante, todos sus rangos son idénticos (rango medio empate $= (n + 1)/2$), de modo que la fórmula del coeficiente de Spearman retorna un valor aritméticamente cercano a 0,5 por construcción, sin reflejar ninguna asociación estadística real. El p -valor de 1,0 confirma que el estadístico observado es perfectamente compatible con la hipótesis nula de independencia.
2. **Popularidad (Y) vs. Bailabilidad (X_2):** Coeficiente $\rho_S = 0,02993045803975003$ con un p -valor *Bootstrap* de 0,0000.
3. **Popularidad (Y) vs. Acusticidad (X_3):** Coeficiente $\rho_S = -0,02661276572105553$ con un p -valor *Bootstrap* de 0,0010.

Para X_2 y X_3 , el p -valor resultó ser sustancialmente menor que el nivel de significancia $\alpha = 0,05$, por lo que **se rechaza la hipótesis nula de independencia en ambos casos**. Sin embargo, la magnitud de los coeficientes obtenidos es reducida: $|\hat{\rho}_S| \approx 0,03$ en ambas variables. Esto indica que, si bien la asociación monótona entre las características sónicas y la popularidad es estadísticamente real y no atribuible al azar muestral, su fuerza práctica es débil. La bailabilidad (X_2) exhibe la asociación positiva más intensa, siendo la variable sónica operativa con mayor poder predictivo sobre la popularidad del artista.

5.4. Hipótesis de Negocio de la Fase 2

La resolución de las pruebas de la Fase 2 orienta la estrategia de la disquera de la siguiente manera:

- **Cola pesada verificada (Riesgo Financiero):** El rechazo de m_0 y el colapso absoluto de las pruebas de bondad de ajuste (AD y CvM con $p = 0,0$) prueban estadísticamente que el éxito en la industria musical se rige por leyes de colas pesadas. Invertir capital esperando un “rendimiento de popularidad promedio” es un error financiero; el sello debe gestionar su catálogo como un portafolio de *Venture Capital*, donde una minoría selecta compensará las inversiones estancadas.
- **Dominancia del Género sobre la Estructura Sonora:** La prueba de Wilcoxon demostró que el género musical causa desplazamientos estocásticos reales en la distribución de éxito. Las decisiones de inversión en distribución masiva deben priorizar el

marco del género, ya que el público penaliza o recompensa un track inicialmente por su categoría antes que por su arquitectura acústica interna.

- **Señal sónica estadísticamente significativa pero de magnitud débil:** Las pruebas de Spearman revelaron que tanto la bailabilidad (X_2 , $\hat{\rho}_S = 0,030$, $p = 0,0000$) como la acusticidad (X_3 , $\hat{\rho}_S = -0,027$, $p = 0,0010$) presentan asociaciones monótonas con la popularidad que son estadísticamente reales, aunque de magnitud reducida. La bailabilidad muestra la relación positiva más robusta: canciones más bailables tienden a asociarse con artistas ligeramente más populares. La acusticidad, por su parte, exhibe una asociación negativa, lo que indica que las producciones con mayor contenido orgánico-acústico están marginalmente asociadas a menores niveles de popularidad en este catálogo. Para la disquera, esto significa que modificar aisladamente la acusticidad o la bailabilidad de una pista producirá un impacto comercial limitado, pero detectable. El éxito obedece a superficies de respuesta multivariadas complejas, lo que justifica la adopción de un modelo no lineal avanzado como la regresión de Kernel de Nadaraya-Watson en la Fase 3 del proyecto, capaz de capturar la curvatura real de la función de respuesta que el análisis por rangos no puede revelar.

6. Fase 3: Regresión No Paramétrica

6.1. Implementación del Estimador de Nadaraya-Watson

Dada la débil pero estadísticamente significativa asociación detectada por las pruebas de Spearman en la Fase 2, se implementó algorítmicamente desde cero el estimador de regresión no paramétrica de Nadaraya-Watson. Este estimador aproxima la función de regresión poblacional $m(x) = \mathbb{E}(Y \mid X = x)$ mediante un promedio ponderado local de las observaciones, donde el peso asignado a cada punto X_i decrece conforme su distancia al punto de evaluación x aumenta:

$$\hat{m}_n(x) = \frac{\sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)}$$

donde $K(\cdot)$ es la función kernel y $h > 0$ es el ancho de banda o parámetro de suaviza-

miento. Se adoptó el **kernel Gaussiano**:

$$K(u) = e^{-\frac{1}{2}u^2}$$

cuyas propiedades de suavidad y decaimiento exponencial lo hacen idóneo para capturar relaciones continuas entre las características sónicas y la popularidad. El ancho de banda se fijó en $h = 0,1$, valor que garantiza un equilibrio adecuado entre sesgo y varianza para el rango de las variables estudiadas.

Se ajustaron dos modelos independientes, uno por cada variable independiente operativa (X_2 y X_3), dado que la variable X_1 (**energy**) se encuentra degenerada con varianza nula. Para cada modelo, las estimaciones $\hat{m}_n(x)$ se calcularon sobre una malla uniforme de 200 puntos en el soporte de cada variable.

6.2. Visualización de los Ajustes

Las Figuras 8 y 9 presentan las curvas de regresión Nadaraya-Watson para X_2 y X_3 , respectivamente, superpuestas sobre los diagramas de dispersión de los datos originales.




Figura 8: Regresión Nadaraya-Watson: Popularidad (Y) vs. Bailabilidad (X_2). Dispersión en azul; curva estimada en rojo. La línea punteada indica el máximo local de la superficie de respuesta ($X_2 \approx 0,885$).




Figura 9: Regresión Nadaraya-Watson: Popularidad (Y) vs. Acusticidad (X_3). Dispersión en verde; curva estimada en morado. La curva exhibe una tendencia levemente decreciente y monótonica en el rango $[0,05, 0,70]$, con una ligera recuperación hacia valores extremos.

Las Figuras 10 y 11 presentan nuevamente los ajustes en formato individual enfatizando la curva de regresión sobre el diagrama de dispersión completo, facilitando la lectura analítica de la forma funcional estimada.




Figura 10: Curva de regresión NW superpuesta sobre diagrama de dispersión completo: Y vs. X_2 (Bailabilidad). $MSE = 0,012272$.




Figura 11: Curva de regresión NW superpuesta sobre diagrama de dispersión completo: Y vs. X_3 (Acusticidad). $MSE = 0,012288$.

6.3. Evaluación del Ajuste: Error Cuadrático Medio

Para determinar cuál característica sónica provee la mejor capacidad explicativa sobre la popularidad, se calculó el Error Cuadrático Medio (MSE) *in-sample* para cada modelo, evaluando el estimador $\hat{m}_n(X_i)$ en cada observación de entrenamiento:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{m}_n(X_i))^2$$

Los resultados obtenidos se sintetizan en la Tabla 4.

Cuadro 4: Error Cuadrático Medio (MSE) de los Modelos Nadaraya-Watson ($h = 0,1$)

Modelo	Variable	MSE	Ranking
NW sobre X_1 (energy)	Intensidad	—	— (variable degenerada)
NW sobre X_2 (danceability)	Bailabilidad	0,012272	1° (mejor)
NW sobre X_3 (acousticness)	Acusticidad	0,012288	2°

La variable X_2 (**danceability**) generó el **mejor ajuste global** con un $\text{MSE} = 0,012272$, marginalmente inferior al de X_3 ($\Delta\text{MSE} \approx 1,58 \times 10^{-5}$). Aunque la diferencia absoluta entre ambos modelos es pequeña, la forma funcional de cada curva revela patrones cualitativamente distintos, con implicaciones estratégicas diferenciadas para la disquera. Este resultado es consistente con la Fase 2: la bailabilidad fue también la variable con el coeficiente de Spearman más elevado en valor absoluto ($\hat{\rho}_S = 0,030$), confirmando que X_2 es la característica sónica con mayor poder predictivo sobre la popularidad del artista.

6.4. Hipótesis de Negocio de la Fase 3

El modelo ganador corresponde al estimador de Nadaraya-Watson ajustado sobre la **bailabilidad** (X_2). A continuación se responde a las preguntas estratégicas de la gerencia con base en la geometría de la curva estimada.

▪ **¿La relación es estrictamente monótona o existe un máximo local?**

La curva de regresión estimada para X_2 no es estrictamente monótona. Exhibe una pendiente positiva creciente desde $X_2 \approx 0,0$ ($\hat{m} \approx 0,410$) hasta alcanzar un **máximo**

local en $X_2 \approx 0,885$ ($\hat{m} \approx 0,421$), tras lo cual la curva desciende levemente hacia $X_2 = 1,0$ ($\hat{m} \approx 0,420$). Esto implica que existe un nivel óptimo de disponibilidad donde la popularidad esperada del artista se maximiza. Concretamente, canciones con un nivel de disponibilidad cercano a 0,885 en la escala normalizada $[0, 1]$ están estadísticamente asociadas a la mayor popularidad esperada en el catálogo estudiado. Este máximo no es detectable mediante el coeficiente de Spearman —que solo mide la monotonía global de la relación— lo que ilustra el valor añadido de la regresión Kernel sobre los métodos de rangos.

■ **¿Qué ocurre si se extrema la característica sónica?**

La curva justifica con claridad que extremar la disponibilidad (llevarla a su valor máximo $X_2 = 1,0$) **no maximiza la popularidad**; por el contrario, la curva penaliza ligeramente el exceso. Esto implica que una producción hipersaturada de elementos rítmicos no traduce automáticamente en mayor éxito comercial. El productor musical debe buscar el punto de máxima respuesta ($X_2 \approx 0,885$) y no caer en la trampa de la hiperoptimización rítmica, que puede alejar a los oyentes de nichos menos orientados al baile.

■ **¿Por qué la curva Kernel supera a una regresión lineal clásica?**

Una regresión lineal clásica impondría una relación de pendiente constante entre X_2 e Y , capturando únicamente la tendencia global y descartando por completo la existencia del máximo local en $X_2 \approx 0,885$. Al hacerlo, le recomendaría a la disquera maximizar ilimitadamente la disponibilidad, lo cual es estadísticamente incorrecto y estratégicamente contraproducente. La estimación por Kernel de Nadaraya-Watson, al ser un estimador no paramétrico *distribution-free*, aproxima fielmente la curvatura real de $m(x) = \mathbb{E}(Y \mid X = x)$ sin imponer ningún supuesto funcional. Esto le permite a la dirección general identificar con precisión el nivel óptimo de producción y establecer umbrales de control de calidad acústica basados en evidencia empírica, en lugar de en supuestos lineales que el propio conjunto de datos rechaza.

7. Fase 4: Conclusiones y Próximos Pasos

7.1. Conclusiones Generales

El análisis integral desarrollado a lo largo de las cuatro fases del proyecto permite sintetizar los hallazgos técnicos más relevantes en los siguientes ejes:

- **La popularidad en la industria musical sigue una distribución no paramétrica de cola pesada.** Las tres pruebas de bondad de ajuste (Kolmogorov-Smirnov, Cramér-von Mises y Anderson-Darling) rechazaron de manera absoluta cualquier ajuste paramétrico clásico sobre Y (p -valores de *Bootstrap* = 0,0000). La distribución empírica de `artist_hotttnesss` exhibe asimetría y cola derecha pesada, confirmando que el éxito masivo es un fenómeno estadísticamente excepcional: la gran mayoría de los artistas se concentra en popularidades medias ($Q_{0,75} = 0,469$), mientras una élite reducida supera valores de 0,72. La industria musical opera bajo un **Efecto Superstar**, incompatible con los modelos lineales y paramétricos de riesgo tradicionales.
- **No existe un estándar sónico único en el catálogo.** Las variables de bailabilidad (X_2) y acusticidad (X_3) presentan alta dispersión y distribuciones multimodales, evidenciando que el catálogo está estructuralmente fragmentado en al menos dos segmentos: producciones electrónicas de alta energía rítmica y producciones orgánicas acústicas. La variable de intensidad (X_1) resultó degenerada, constituyendo una limitación de la base de datos que impide conclusiones sobre ese atributo.
- **El género musical determina desplazamientos reales en la popularidad.** La prueba de Wilcoxon (Mann-Whitney U) rechazó la hipótesis de homogeneidad distributiva entre Rock y Electronic ($Z = 8,245$, $p = 0,0000$), demostrando que el género actúa como un factor de estratificación estocástica sobre Y . No obstante, la comparación de las FDEs por género revela que las curvas se cruzan, lo que implica que el género no garantiza éxito absoluto; existen artistas de alta popularidad en todos los géneros estudiados.
- **Las características sónicas muestran asociaciones significativas pero de magnitud débil con la popularidad.** Las pruebas de correlación por rangos de Spearman rechazaron la independencia para X_2 ($\hat{\rho}_S = 0,0299$, $p = 0,0000$) y X_3 ($\hat{\rho}_S = -0,0266$, $p = 0,0010$). La bailabilidad presenta una asociación positiva y la acusticidad una asociación negativa con la popularidad. Si bien ambas relaciones son estadísticamente

reales, sus coeficientes reducidos ($|\hat{\rho}_S| \approx 0,03$) indican que ninguna variable sónica por sí sola constituye un predictor potente de la popularidad cuando se analiza de forma univariada y monótona.

- **La regresión de Nadaraya-Watson revela el nivel óptimo de bailabilidad.** La estimación no paramétrica de la función de regresión $\hat{m}(X_2)$ captura una relación no lineal con un máximo local en $X_2 \approx 0,885$ ($\hat{m} \approx 0,421$). Este resultado complementa los hallazgos de Spearman: aunque la asociación monótona global es débil, la curva Kernel evidencia que existe una región óptima de bailabilidad donde la popularidad esperada se maximiza, información invisible para los métodos de rangos lineales. El modelo sobre bailabilidad obtuvo el menor MSE ($\text{MSE}_{X_2} = 0,012272 < \text{MSE}_{X_3} = 0,012288$).

7.2. Recomendaciones de Negocio

Traduciendo los hallazgos técnicos anteriores en directrices estratégicas claras y accionables para la disquera:

- **Calibrar la bailabilidad hacia el umbral óptimo identificado.** El equipo de producción debe orientar sus decisiones hacia una bailabilidad objetivo de $X_2 \in [0,85, 0,92]$, el rango donde la curva de Nadaraya-Watson estima la mayor popularidad esperada. Aunque la magnitud de la ganancia es moderada en términos absolutos —consistente con el $\hat{\rho}_S = 0,030$ de Spearman—, representa la palanca sónica más accionable disponible en el catálogo analizado. Canciones con valores extremos ($X_2 > 0,95$) o demasiado bajos ($X_2 < 0,30$) están estadísticamente asociadas a menores popularidades esperadas.
- **Gestionar el catálogo como un portafolio de Venture Capital.** Dado el Efecto Superstar confirmado estadísticamente, la rentabilidad del sello no depende del éxito promedio de su catálogo, sino de la concentración selectiva en proyectos con potencial de penetrar la cola derecha de la distribución de popularidad. Se recomienda asignar el 20 % del presupuesto de producción a proyectos de alto riesgo con perfiles acústicos diferenciados (artistas con propuestas sonoras no convencionales), con la expectativa actuarial de que una minoría compensará el portafolio completo.
- **Establecer estrategias diferenciadas por segmento sónico.** La bimodalidad confirmada en acusticidad y bailabilidad exige que el sello opere con al menos dos líneas de producción especializadas: una orientada al segmento electrónico-bailable (baja acusti-

cidad, alta disponibilidad) y otra al segmento orgánico-acústico. Unificar la estrategia de producción bajo un único estándar sónico es estadísticamente subóptimo.

- **Priorizar el Rock y Electronic para volumen, Pop para posicionamiento premium.** La distribución de frecuencias y la FDE segmentada indican que el Rock domina el catálogo en volumen (3,413 registros en la tabla de géneros), pero el Pop muestra una FDE desplazada hacia niveles de popularidad superiores en los rangos altos ($Y > 0,6$). La estrategia óptima consiste en mantener la producción masiva en Rock y Electronic como base de ingresos recurrentes, mientras se seleccionan inversiones estratégicas de alto perfil en proyectos Pop orientados a la exposición masiva y el posicionamiento de marca del sello.

7.3. Próximos Pasos

Con base en las limitaciones identificadas y las oportunidades de mejora analítica, se proponen las siguientes líneas de investigación futuras:

1. **Incorporación de la variable energy mediante auditoría y sustitución.** La degeneración total de X_1 en la base de datos representa la limitación más crítica del análisis. Se recomienda realizar una auditoría técnica en la fuente original (Million Song Dataset) para recuperar los valores reales de intensidad, o bien sustituir X_1 por *aggressiveness* o *brightness* de la tabla `audio_features`, variables que sí poseen varianza positiva y que conceptualmente aproximan la intensidad perceptual. Esto permitiría ajustar un modelo de regresión Kernel multivariado para capturar las superficies de respuesta conjuntas de las características sónicas.
2. **Extensión a estimación Kernel multivariada y selección óptima del ancho de banda.** El análisis actual ajustó modelos univariados con un ancho de banda fijo $h = 0,1$. Una línea natural de extensión consiste en implementar (i) un estimador de Nadaraya-Watson multivariado con kernel producto para modelar $\mathbb{E}(Y \mid X_2, X_3)$ simultáneamente, y (ii) un algoritmo de validación cruzada *leave-one-out* (LOOCV) para seleccionar el h óptimo minimizando el MSE fuera de muestra. Esta extensión permitiría detectar efectos de interacción entre la disponibilidad y la acusticidad que el análisis univariado no puede capturar, aportando directrices de producción significativamente más precisas para el equipo de la disquera.